

Exposé

Hybride Multilabel-Klassifikation von Online-Kommunikationsverhalten bezüglich der Netiquette

(Multilabel Classification of Online Communication Behaviour - Digital Netiquette)

Vu Hoang Anh Dang – MatrNr: 09890224

Betreuer: Prof. Dr. Peter Mandl
Dr. Martin Häusl

Competence Center Wirtschaftsinformatik (CCWI)
Institut für Anwendungen des Maschinellen Lernens und Intelligenter Systeme (IAMLIS)
Hochschule München

E-Mail: peter.mandl@hm.edu

<i>I.</i>	<i>Einleitung.....</i>	<i>4</i>
<i>II.</i>	<i>Stand der Forschung</i>	<i>5</i>
<i>III.</i>	<i>Proposal.....</i>	<i>6</i>
	1. Motivation und Aufgabenstellung.....	6
	2. Methodik und Durchführung	6
	2.1. Datenerhebung und -speicherung:	6
	2.2. Datenbereinigung und -vorverarbeitung:	7
	2.3. Modellierung und Klassifikation:	8
	2.4. Evaluation der Modelle:.....	9
	2.5. Visualisierung und Erkenntnisgewinn:	9
	3. Erwartete Ergebnisse und Ausblick	9
	4. Sonstige Inhalte.....	10
<i>IV.</i>	<i>Bearbeitungsphase.....</i>	<i>10</i>
	<i>Bibliography.....</i>	<i>12</i>

Zusammenfassung: Diese Masterarbeit befasst sich mit der automatisierten Analyse und Klassifikation von Netiquette-relevantem Kommunikationsverhalten in Online-Plattformen. Ziel der Arbeit ist die Entwicklung eines flexiblen Multilabel-Klassifikationsansatzes, der sowohl allgemeine sprachliche Verhaltensmuster als auch plattformspezifische Netiquette-Regelwerke berücksichtigen kann. Im Fokus steht dabei die Kombination moderner Methoden der Datenanalyse mit Verfahren der Natural Language Processing (NLP).

Methodisch verfolgt die Arbeit einen hybriden Ansatz, der die komplementären Stärken feinjustierter Transformer-Modelle und Large Language Models (LLMs) vereint. Ein BERT-basiertes Modell dient als Hauptklassifikator für stabile, plattformübergreifende Kernkategorien wie Toxic, Insult, Impolite und Polite. Zur Sicherstellung der Flexibilität bei unterschiedlichen Plattformen werden LLMs als adaptives Zusatzmodul eingesetzt, das plattformspezifische Kategorien (z. B. Spam, Werbung, Jugendschutz oder Rufschädigung) regel- und promptbasiert abbilden kann. Zudem fungieren LLMs als Meta-Reviewer für ambivalente oder schwer interpretierbare Fälle.

Die Datengrundlage der Arbeit besteht primär aus deutschsprachigen, moderierten Online-Beiträgen, insbesondere aus einem von gutefrage.net bereitgestellten Datensatz. Aufgrund der begrenzten Datenmenge wird das Training des BERT-Modells durch translationsbasierte Datenerweiterung ergänzt: Hierzu werden große, manuell annotierte englischsprachige Datensätze maschinell ins Deutsche übersetzt und ausschließlich als zusätzliche Trainingsdaten verwendet. Die Evaluation der Modelle erfolgt ausschließlich auf echten deutschsprachigen Daten, um die Praxisrelevanz im deutschsprachigen Raum sicherzustellen.

Durch die klare Trennung zwischen stabilen Kernkategorien und flexiblen, plattformspezifischen Netiquette-Aspekten leistet die Arbeit einen Beitrag zur Behavioral Data Analytics und zeigt, wie hybride KI-Systeme zur skalierbaren und anpassbaren Moderation digitaler Kommunikationsräume eingesetzt werden können.

Schlüsselwörter: Data Analytics · Machine Learning · Natural Language Processing · Text Classification · Netiquette · Online-Multilabelkommunikation · Python · Sentiment Analyse

I. Einleitung

Die Digitalisierung hat nicht nur wirtschaftliche Prozesse, sondern auch zwischenmenschliche Kommunikation grundlegend verändert. In sozialen Netzwerken, Online-Foren und Chat-Plattformen werden täglich Millionen von Textnachrichten ausgetauscht, die einen Einblick in das Kommunikationsverhalten moderner Gesellschaften geben. Diese Form der digitalen Interaktion ist ein wesentlicher Bestandteil des öffentlichen und beruflichen Lebens geworden.

Gleichzeitig hat die zunehmende Anonymität im Internet dazu geführt, dass respektlose, aggressive oder diskriminierende Ausdrucksweisen häufiger auftreten. Die Wahrung der sogenannten *Netiquette* – also die Einhaltung von Regeln für respektvolle digitale Kommunikation [1] – ist daher zu einer zentralen Herausforderung der digitalen Gesellschaft geworden.

Ein besseres Verständnis solcher Kommunikationsmuster und deren automatisierte Analyse kann nicht nur zur Verbesserung der digitalen Diskussionskultur beitragen, sondern auch datenbasierte Erkenntnisse über Kommunikationsstile, Themen und Stimmungen liefern. In diesem Zusammenhang untersucht diese Masterarbeit, wie moderne Methoden der Datenanalyse, der Sprachverarbeitung (NLP) und der Large Language Models (LLMs) eingesetzt werden können, um Verhaltensmuster in Online-Kommunikation zu erkennen, zu klassifizieren und sichtbar zu machen. Darüber hinaus ist zu berücksichtigen, dass Kommunikationsverhalten in sozialen Medien selten eindimensional ist. Einzelne Beiträge können gleichzeitig mehrere sprachliche oder inhaltliche Eigenschaften aufweisen – etwa eine Kombination aus Ironie, Beleidigung, politischer Positionierung oder impliziter Diskriminierung. Aus diesem Grund wird das Problem in dieser Arbeit nicht als reine binäre oder multiklassige Klassifikation, sondern als Multilabel-Klassifikationsaufgabe modelliert.

II. Stand der Forschung

Die Kombination von klassischen feingetunten BERT-Modellen mit modernen Large Language Models (LLMs) gewinnt in der aktuellen NLP-Forschung zunehmend an Bedeutung, insbesondere wenn es darum geht, semantisch anspruchsvolle oder mehrschichtige Klassifikationsaufgaben zu lösen.

Ein neuartiger hybrider Ansatz für multidimensionale Klassifikationsprobleme wurde beispielsweise im Bereich der aspektbasierten Sentimentanalyse untersucht. Zhang et al. [2] schlagen eine Kombination aus einem BERT-basierten Klassifikator und einem LLM vor, wobei beide Methoden zur Extraktion und Bewertung feingranularer sentimentbezogener Informationen kombiniert werden, um Leistungsvorteile gegenüber Einzelmodellen zu erzielen. Dabei zeigt der hybride Ansatz insgesamt eine bessere Performance bei der Verarbeitung komplexer Aufgaben als die isolierte Anwendung von BERT oder LLM-basierten Methoden allein.

Auch im Bereich der Fake-News-Erkennung wurde der synergistische Einsatz von BERT und generativen LLM-Komponenten untersucht. Dhiman et al. [3] berichten, dass ein Hybridmodell, das die kontextuellen Stärken von BERT mit den generativen Fähigkeiten von GPT-ähnlichen LLMs kombiniert, bei der Erkennung und Klassifikation manipulierter Inhalte bessere Ergebnisse erzielt als klassische BERT-Modelle.

Ein weiterer relevanter Forschungsbeitrag zu hybriden Klassifikationsansätzen ist die Studie „Enhancing Multi-label Emotion Prediction through Rule-based Voting with LLM and BERT Variants“ [4]. Die Autoren kombinieren feinjustierte BERT-Modelle mit Large Language Models, um mehrdeutige Multi-Label-Klassifikationsaufgaben zu lösen. Dabei wird BERT als primärer Klassifikator eingesetzt, während LLMs zur Nachbewertung und Entscheidungs-unterstützung bei schwierigen Fällen dienen. Die Ergebnisse zeigen, dass der hybride Ansatz sowohl reine BERT- als auch reine LLM-Modelle übertrifft. Obwohl die Arbeit auf Emotionserkennung fokussiert ist, sind die zugrunde liegenden methodischen Prinzipien direkt auf andere Multilabel-Klassifikationsaufgaben, wie etwa die Netiquette-Analyse von Online-Kommunikation in dieser Forschung, übertragbar.

Ein weiterer aktueller Forschungsbeitrag untersucht die Leistungsfähigkeit moderner Moderationssysteme bei der Erkennung von Hate Speech in deutschsprachigen Online-Kommentaren. Studie von Weber et al. (2025) [5] vergleichen Large Language Models wie GPT-4 mit bestehenden Moderationssystemen wie der Perspective API und der OpenAI Moderation API auf dem HOCON34k-Datensatz. Die Studie zeigt, dass moderne LLM-basierte Ansätze in vielen Fällen eine höhere Erkennungsleistung erreichen als klassische Moderationssysteme. Gleichzeitig verdeutlichen die Ergebnisse die Herausforderungen bei der zuverlässigen automatisierten Moderation komplexer Online-Kommunikation und unterstreichen die Bedeutung geeigneter Evaluationsmetriken wie F2-Score, MCC und S-Score für die Bewertung solcher Systeme.

Zusammenfassend zeigt der aktuelle Stand der Forschung, dass hybride Ansätze aus BERT-Modellen und LLMs ein vielversprechendes Paradigma für anspruchsvolle Klassifikations-aufgaben darstellen. Insbesondere für Multi-Label-Settings und kontextabhängige Entscheidungen bieten solche Kombinationen deutliche Vorteile. Eine systematische Anwendung dieser Ansätze auf die Netiquette-Klassifikation von Online-Kommunikation – insbesondere unter Berücksichtigung plattform-spezifischer Regeln und deutschsprachiger Daten – ist bislang jedoch kaum untersucht und bildet die Forschungslücke, an die diese Masterarbeit anknüpft.

III. Proposal

1. Motivation und Aufgabenstellung

Während die öffentliche Aufmerksamkeit zunehmend auf Themen wie Hassrede, Cybermobbing und toxische Kommunikation gerichtet ist, fehlt bislang eine datengetriebene, differenzierte Betrachtung verschiedener Kommunikationsformen im digitalen Raum. Bisherige Forschungsarbeiten konzentrieren sich überwiegend auf binäre Klassifikationen, beispielsweise die Unterscheidung zwischen „toxisch“ und „nicht toxisch“ [6]. Dies führt dazu, dass bestehende Klassifikationsmodelle nur begrenzt in der Lage sind, die Mehrdimensionalität der Online-Kommunikation abzubilden.

Diese Masterarbeit setzt genau hier an. Sie verfolgt das Ziel, ein Multilabel-Klassifikationsmodell zu entwickeln, das digitale Kommunikationsverhalten in verschiedene Netiquette-relevante stabile Kernkategorien einteilt. Damit soll die Mehrdimensionalität menschlicher Online-Kommunikation besser erfasst werden. Durch die Kombination von datengetriebene Transformer-Modelle und LLM-basierten Methoden sollen sowohl explizite als auch implizite Kommunikationsmuster erkannt werden.

Neben der reinen Klassifikation liegt ein besonderer Fokus auf der Integration in einen datenanalytischen Prozess – von der Datensammlung über die Modellierung und Evaluation (Python) bis hin zur Visualisierung der Ergebnisse (Tableau, Plotly). Somit leistet die Arbeit nicht nur einen wissenschaftlichen Beitrag zur *Behavioral Data Analytics*, sondern zeigt auch praxisnahe Anwendungsmöglichkeiten auf, zum Beispiel wie Unternehmen und Plattformen digitale Kommunikation gezielt analysieren und verbessern können.

Auf Basis der beschriebenen Problemstellung ergeben sich folgende Forschungsfragen, die den analytischen Kern dieser Masterarbeit bilden:

RQ1: *Wie können öffentlich verfügbare Online-Kommentare mithilfe moderner NLP-Modelle (BERT und LLMs) zuverlässig in mehrere gleichzeitig auftretende Netiquette-Kategorien klassifiziert werden*

RQ2: *Wie können heterogene, manuell annotierte Datensätze (Toxicity, Personal Attacks, Politeness, Aggression) zu einem konsistenten multilabel-fähigen Netiquette-Labelschema zusammengeführt werden?*

RQ3: *Inwiefern unterscheidet sich die Klassifikationsleistung eines hybriden Ansatzes aus BERT-Modellen und Large Language Models (LLMs) von der Leistung der jeweiligen Einzelmodelle?*

RQ4: *Wie lässt sich ein hybrides Klassifikationssystem so gestalten, dass es flexibel an unterschiedliche plattformspezifische Netiquette-Regelwerke angepasst werden kann?*

2. Methodik und Durchführung

Die Durchführung dieser Arbeit orientiert sich am klassischen Data-Analytics-Prozess und kombiniert Verfahren der Sprachverarbeitung, maschinelles Lernen (BERT) sowie moderne LLM-Technologien. Ziel ist es, ein datenanalytisches Verfahren zur automatisierten Erkennung und Analyse von Kommunikationsverhalten im digitalen Raum zu entwickeln.

2.1. Datenerhebung und -speicherung:

Für die Untersuchung der multilabel-basierten Netiquette-Klassifikation werden ausschließlich öffentlich verfügbare, annotierte Datensätze aus dem Bereich der Online-Kommunikation sowie ein bereitgestellter, moderierter deutschsprachiger Datensatz herangezogen. Ziel der Datenerhebung ist es, sowohl stabile, plattformübergreifende Kommunikationsmuster als auch plattform-spezifische Netiquette-Verstöße abzudecken.

Der gutefrage.net-Datensatz umfasst moderierte Beiträge in Form von Fragen, Antworten und

Kommentaren. Neben dem eigentlichen Textinhalt enthalten die Daten Informationen zum Moderationsstatus sowie zu konkreten Moderationsgründen (z. B. persönliche Angriffe, Spam, Werbung, jugendschutzrelevante Inhalte). Diese Moderationsgründe bilden reale, plattformspezifische Netiquette-Kategorien ab und werden als Goldstandard für die Evaluation sowie zur Abbildung plattformabhängiger Regeln verwendet. Der Moderationsstatus selbst wird nicht als Klassifikationslabel interpretiert, sondern dient als zusätzlicher Hinweis auf potenziell ambivalente oder strittige Fälle.

Da der Umfang deutschsprachiger, hochwertig annotierter Netiquette-Daten begrenzt ist, wird die Datengrundlage für das Training des Klassifikationsmodells durch eine translationsbasierte Datenerweiterung ergänzt. Hierzu werden etablierte, englischsprachige Datensätze mit manueller Annotation (z. B. zu Toxicity, Beleidigungen oder Höflichkeit) maschinell ins Deutsche übersetzt. Zur Erfassung toxischer und beleidigender Sprachmuster wird der *Jigsaw Toxic Comment Dataset* [7] genutzt, während spezifische persönliche Angriffe über den *Wikipedia Personal Attacks Dataset* [8] abgebildet werden. Höfliche und unhöfliche Ausdrucksweisen werden durch den *Stanford Politeness Corpus* [9] ergänzt. Zusätzlich liefert der *Wikipedia Detox Dataset* [10] neutrale bzw. leicht aggressive Beiträge, die zur differenzierten Identifikation von „Impoliteness“ beitragen.

Diese übersetzten Daten dienen ausschließlich als zusätzliche Trainingsdaten und werden als Silver Labels betrachtet. Die finale Evaluation der Modelle erfolgt ausschließlich auf echten deutschsprachigen Daten.

Da die verwendeten Datensätze unterschiedliche Annotation-Schemata und Labeldefinitionen besitzen, wird zunächst ein einheitliches Multilabel-Annotationsschema definiert. Die ursprünglichen Labels der einzelnen Datensätze werden mithilfe festgelegter Mapping-Regeln auf die vier Kernkategorien Toxic, Insult, Impolite und Polite abgebildet. Beispielsweise werden Annotationen wie toxic aus dem Jigsaw Toxic Comment Dataset der Kategorie Toxic zugeordnet, während Labels aus dem Wikipedia Personal Attacks Dataset der Kategorie Insult zugeordnet werden. Annotationen aus dem Stanford Politeness Corpus werden auf die Kategorien Polite und Impolite abgebildet. Eine solche Harmonisierung unterschiedlicher Annotation-Schemata ist ein gängiger Ansatz, wenn mehrere Hate-Speech- oder Online-Kommunikationsdatensätze gemeinsam für das Training von Klassifikationsmodellen verwendet werden (vgl. Schmidt & Wiegand, 2017 [6]; Walsh, 2020 [11]).

Durch die gezielte Zusammenführung dieser heterogenen Datenquellen entsteht ein einheitlicher, multilabel-fähiger Datensatz mit den vier Kernlabels Toxic, Insult, Impolite und Polite. Die Verarbeitung und Integration der Daten erfolgt in Python, wobei Reinigungs-, Normalisierungs- und Mapping-Regeln definiert werden, um die Konsistenz und Reproduzierbarkeit der Datengrundlage sicher-zustellen.

2.2. Datenbereinigung und -vorverarbeitung:

Im Rahmen der Datenbereinigung und -vorverarbeitung werden alle verwendeten Datensätze systematisch aufbereitet, um eine konsistente und vergleichbare Grundlage für das Modelltraining und die Evaluation sicherzustellen. Dabei wird zwischen übersetzten Trainingsdaten (Silver Labels) und echten deutschsprachigen Moderationsdaten (Gold Labels) unterschieden.

Zunächst werden sämtliche Textdaten in ein einheitliches Format überführt. Leere Einträge, extrem kurze Texte sowie Beiträge ohne relevanten Textinhalt (z. B. reine Verweise oder technische Platzhalter) werden entfernt. Zusätzlich erfolgt die Bereinigung von HTML-Artefakten, Sonderzeichen und redundanten Leerzeichen. Die ursprüngliche Groß- und Kleinschreibung bleibt erhalten, da sie für kontextuelle Transformer-Modelle semantische Informationen tragen kann.

Für die maschinell aus dem Englischen ins Deutsche übersetzten Datensätze wird eine zusätzliche Qualitätskontrolle durchgeführt. Unvollständige oder offensichtlich fehlerhafte Übersetzungen werden ausgeschlossen, um die Qualität der Trainingsdaten sicherzustellen. Darüber hinaus werden Duplikate und nahezu identische Texte entfernt, um Verzerrungen im Lernprozess zu vermeiden.

Die Label-Zuordnung erfolgt gemäß einem klar definierten Multilabel-Schema, das zwischen stabilen Kernkategorien und plattformspezifischen Kategorien unterscheidet. Für das Training des BERT-Modells werden ausschließlich die plattformübergreifenden Kernlabels Toxic, Insult, Impolite und Polite verwendet. Die ursprünglichen Annotationen der englischsprachigen Datensätze werden mithilfe festgelegter Mapping-Regeln auf dieses gemeinsame Labelschema abgebildet, wobei Mehrfachzuweisungen erhalten bleiben.

Für den gutefrage.net-Datensatz werden die vorhandenen Moderationsgründe auf die entsprechenden Kern- bzw. plattformspezifischen Kategorien gemappt. Der Moderationsstatus selbst wird nicht als Klassifikationslabel verwendet, sondern dient ausschließlich als Indikator für potenziell ambivalente oder strittige Beiträge, die im weiteren Verlauf gesondert analysiert werden können.

Die Aufteilung der Daten in Trainings-, Validierungs- und Testmengen erfolgt so, dass die Evaluation ausschließlich auf echten deutschsprachigen Daten mit Gold-Labels basiert. Übersetzte Datensätze werden ausschließlich für das Training des BERT-Modells herangezogen, um eine Verzerrung der Evaluation zu vermeiden.

Alle Schritte der Datenbereinigung und -vorverarbeitung werden in Python umgesetzt und dokumentiert, um Transparenz, Reproduzierbarkeit und Nachvollziehbarkeit des methodischen Vorgehens sicherzustellen.

2.3. Modellierung und Klassifikation:

Die Modellierung folgt einem hybriden Klassifikationsansatz, der die Stärken feinjustierter Transformer-Modelle mit den flexiblen Reasoning-Fähigkeiten von Large Language Models (LLMs) kombiniert. Ziel ist es, sowohl stabile, plattformübergreifende Netiquette-Muster zuverlässig zu erkennen als auch plattformspezifische Regelwerke flexibel abzubilden:

(A) BERT-basierte Multilabel-Klassifikation:

Als Hauptklassifikator wird ein vortrainiertes BERT-Modell eingesetzt, das für die multilabelbasierte Textklassifikation feinjustiert wird. Das Modell wird ausschließlich auf den definierten Kernkategorien der Netiquette (Toxic, Insult, Impolite, Polite) trainiert, da diese als sprachlich stabile und plattformunabhängige Merkmale betrachtet werden. Die Klassifikation erfolgt im Multilabel-Setting, sodass einem Text mehrere Labels gleichzeitig zugewiesen werden können.

(B) LLM-basierte Klassifikation:

Zur Erhöhung der Flexibilität und zur Abbildung plattformspezifischer Netiquette-Regeln wird das BERT-Modell durch eine zusätzliche LLM-Komponente ergänzt. Diese wird nicht im Trainingsprozess, sondern ausschließlich in der Inferenzphase eingesetzt. Dabei übernimmt das LLM zwei zentrale Funktionen.

Erstens fungiert es als Meta-Reviewer für ambivalente oder widersprüchliche Klassifikationsfälle. Texte, bei denen das BERT-Modell niedrige Konfidenzwerte oder inkonsistente Labelkombinationen erzeugt, werden gezielt an das LLM weitergeleitet. Auf Basis kontextueller Informationen sowie explizit definierter Netiquette-Regeln kann das Modell diese Fälle neu bewerten oder eine begründete Einschätzung liefern.

Zweitens ermöglicht das LLM die flexible Klassifikation plattformspezifischer Kategorien, die nicht Teil des BERT-Trainings sind (z. B. Spam, Werbung, Jugendschutz oder Rufschädigung). Diese Kategorien werden promptbasiert definiert und können je nach Plattform angepasst werden, ohne dass ein erneutes Training des Kernmodells erforderlich ist.

Als LLM-Komponente kommen moderne generative Sprachmodelle wie GPT-4o oder offene Modelle der Llama-3-Familie zum Einsatz. Diese Modelle werden nicht für das Training des Klassifikators verwendet, sondern dienen ausschließlich als ergänzende Entscheidungsinstanz in der Inferenzphase, insbesondere zur Bewertung ambivalenter Fälle.

(C) Hybridisierung: Kombination von BERT und LLM

Die finale Klassifikationsentscheidung basiert auf einer klaren Trennung der Zuständigkeiten:

Die Vorhersagen des BERT-Modells bilden die Grundlage für die stabilen Kernkategorien, während LLM-basierte Bewertungen ergänzend für Sonderfälle und plattformspezifische Regeln herangezogen werden. Dieser modulare Aufbau ermöglicht eine hohe Anpassungsfähigkeit an unterschiedliche Plattformen bei gleichzeitiger Robustheit der Klassifikation. Mit dieser Masterarbeit wird untersucht, inwiefern ein hybrider Ansatz aus BERT und LLMs die Klassifikationsleistung steigern kann; die Arbeit dient damit als empirischer Nachweis für das Potenzial solcher hybriden Systeme.

Durch diese hybride Modellierung wird versucht, um sicherzustellen, dass das System sowohl datengetrieben als auch regel- und kontextsensitiv arbeitet und damit den Anforderungen realer Moderationsszenarien gerecht wird.

2.4. Evaluation der Modelle:

Die Modelle werden anhand etablierter Metriken (*Precision, Recall, F1-Score, F2-Score, S-Score [12] und MCC*) evaluiert. Zusätzlich werden Fehleranalysen durchgeführt, um Stärken und Schwächen der jeweiligen Ansätze zu identifizieren.

2.5. Visualisierung und Erkenntnisgewinn:

Zur Ergebnisdarstellung werden Python-Visualisierungen (*matplotlib, seaborn, plotly*) oder Tableau Public angesetzt. Während Python für explorative Analysen und Modellmetriken verwendet wird, dient Tableau zur Erstellung eines interaktiven Dashboards, das Kommunikationsmuster, Häufigkeiten und Trends der Netiquette-Kategorien anschaulich darstellt.

3. Erwartete Ergebnisse und Ausblick

Im Rahmen dieser Masterarbeit werden mehrere Ergebnisse erwartet, die sowohl wissenschaftliche als auch praktische Relevanz besitzen. Zunächst wird davon ausgegangen, dass das feinjustierte BERT-Modell in der Lage ist, die definierten plattformübergreifenden Kernkategorien der Netiquette (Toxic, Insult, Impolite, Polite) zuverlässig im Multilabel-Setting zu klassifizieren. Insbesondere durch die Kombination aus echten deutschsprachigen Gold-Daten und translationsbasierten Trainingsdaten wird eine robuste Modellleistung auch bei begrenzter Datenverfügbarkeit erwartet.

Darüber hinaus wird angenommen, dass der hybride Ansatz aus BERT und LLMs gegenüber einem reinen BERT-Modell Vorteile bei ambivalenten oder kontextabhängigen Fällen bietet. Insbesondere bei widersprüchlichen Klassifikationen oder niedrigen Konfidenzwerten des BERT-Modells wird erwartet, dass die LLM-Komponente durch kontextuelle Nachbewertung zu konsistenteren und besser nachvollziehbaren Entscheidungen beiträgt. Damit soll gezeigt werden, dass LLMs als ergänzende Entscheidungsinstanz einen messbaren Mehrwert liefern können, ohne den stabilen Kern des Systems zu beeinträchtigen.

Ein weiteres erwartetes Ergebnis ist der Nachweis der Flexibilität und Übertragbarkeit des vorgeschlagenen Klassifikationssystems. Durch die klare Trennung zwischen datengetriebenen Kernkategorien und promptbasiert definierten, plattformspezifischen Netiquette-Regeln soll demonstriert werden, dass sich das System mit geringem Aufwand an unterschiedliche Plattformen anpassen lässt, ohne ein erneutes Training des BERT-Modells zu erfordern. Dies erhöht die Praxisrelevanz des Ansatzes erheblich.

Im Ausblick bieten sich mehrere Ansatzpunkte für weiterführende Forschung. So könnten zukünftige Arbeiten den hybriden Ansatz auf zusätzliche Sprachen oder weitere Netiquette-Kategorien ausweiten oder eine teilautomatisierte Annotation plattformspezifischer Regelwerke untersuchen. Ebenso wäre eine vertiefte Analyse der Interpretierbarkeit und Transparenz von LLM-gestützten Entscheidungen denkbar, etwa durch erklärende Begründungen oder Nutzerfeedback. Darüber hinaus könnten reale Moderationsprozesse stärker integriert werden, um den Ansatz in produktionsnahen Szenarien weiter zu evaluieren.

Insgesamt leistet die Arbeit einen Beitrag zur Entwicklung flexibler, datengetriebener Moderationssysteme und zeigt auf, wie hybride NLP-Ansätze zur nachhaltigen Gestaltung digitaler Kommunikationsräume eingesetzt werden können.

4. Sonstige Inhalte

Grobe Gliederung der Masterarbeit

a) *Einleitung*

- Hintergrund und Relevanz der digitalen Kommunikation
- Definition von Netiquette und Problemstellung
- Zielsetzung und Forschungsfragen
- Aufbau der Arbeit

b) *Theoretischer Rahmen und Forschungsstand*

- Grundlagen der Netiquette und digitalen Kommunikationsverhaltens
- Überblick über Machine Learning, NLP und LLMs
- Stand der Forschung zu Textklassifikation und Online-Kommunikation
- Forschungslücken und theoretische Einordnung.

c) *Datenbasis und Methodik*

- Datenerhebung und Datenquellen
- Datenaufbereitung und Labeling-Prozess (Multilabel-Ansatz)
- Modellierung: BERT (Transformer) vs. LLM-basierte Ansätze
- Evaluationsmetriken und Validierung

d) *Analyse und Ergebnisse*

- Trainingsergebnisse der Modelle
- Vergleich der Ansätze (Performance, Interpretierbarkeit, Fehleranalyse)
- Visualisierung von Kommunikationsmustern
- Ableitung zentraler Erkenntnisse

e) *Diskussion*

- Interpretation der Ergebnisse im Kontext der Netiquette
- Limitationen und methodische Herausforderungen
- Vergleich mit bestehenden Studien

f) *Fazit und Ausblick*

- Zusammenfassung der zentralen Ergebnisse
- Implikationen für Forschung und Praxis
- Perspektiven für zukünftige Arbeiten im Bereich *Digital Communication Analytic*

IV. Bearbeitungsphase

Die Bearbeitungsphase der Masterarbeit gliedert sich in einen inhaltlich-methodischen (Abbildung 1) und einen administrativ-organisatorischen Prozess (Abbildung 2), die eng miteinander verzahnt sind. Während der methodische Teil den Forschungsablauf – von der Datenerhebung über die Modellierung bis zur Ergebnisvisualisierung – beschreibt, definiert der organisatorische Teil die formalen Schritte des wissenschaftlichen Arbeitsprozesses, die im Rahmen der Prüfungsordnung der Hochschule München vorgesehen sind.



Abbildung 2

Zeitraum	Arbeitsschritte
1. Monat	Literaturrecherche, Themenabgrenzung, Definition der Forschungsfragen, Aufbau der Datenbasis
2. Monat	Datensammlung, Datenbereinigung, Vorverarbeitung (Tokenisierung, Labeling) 1. Zwischenstand Präsentation
3. Monat	Entwicklung und Training klassischer Machine-Learning-Modelle
4. Monat	Einsatz und Evaluation von LLM-basierten Klassifikationsansätzen. Vergleich der Annotationen / Zero- vs Few-Shot 2. Zwischenstand Präsentation
5. Monat	Vergleichsanalyse der Modelle, Visualisierung der Ergebnisse (Python, Tableau)
6. Monat (Abschlussphase)	Interpretation, Schreiben der Kapitel „Diskussion“ und „Fazit“, Endkorrektur und Abgabe 3. Abschluss Präsentation

Abbildung 1

Bibliography

- [1] L. Scheuermann und G. Taylor, „Netiquette“, *Internet Res.*, Bd. 7, Nr. 4, S. 269–273, 1997.
- [2] Y. Zhang, H. Xu, D. Zhang, und R. Xu, „A Hybrid Approach to Dimensional Aspect-Based Sentiment Analysis Using BERT and Large Language Models“, *Electronics*, Bd. 13, Nr. 18, S. 3724, Jan. 2024, doi: 10.3390/electronics13183724.
- [3] P. Dhiman, A. Kaur, D. Gupta, S. Juneja, A. Nauman, und G. Muhammad, „GBERT: A hybrid deep learning model based on GPT-BERT for fake news detection“, *Heliyon*, Bd. 10, Nr. 16, S. e35865, Aug. 2024, doi: 10.1016/j.heliyon.2024.e35865.
- [4] M. Le, C. Phan, T. Nguyen, und S. Nguyen, *Enhancing Multi-label Emotion Prediction through Rule-based Voting with LLM and BERT Variants*. 2025. doi: 10.21203/rs.3.rs-7501928/v1.
- [5] M. Weber, M. Huber, M. Auch, A. Döschl, M.-E. Keller, und P. Mandl, „Digital Guardians: Can GPT-4, Perspective API, and Moderation API reliably detect hate speech in reader comments of German online newspapers?“, 2. Januar 2025, *arXiv*: arXiv:2501.01256. doi: 10.48550/arXiv.2501.01256.
- [6] A. Schmidt und M. Wiegand, „A survey on hate speech detection using natural language processing“, in *Proceedings of the fifth international workshop on natural language processing for social media*, 2017, S. 1–10. Zugegriffen: 13. November 2025. [Online]. Verfügbar unter: <https://aclanthology.org/W17-1101/>
- [7] „affahrizain/jigsaw-toxic-comment · Datasets at Hugging Face“. Zugegriffen: 13. November 2025. [Online]. Verfügbar unter: <https://huggingface.co/datasets/affahrizain/jigsaw-toxic-comment/viewer>
- [8] „Wikipedia Talk Labels: Personal Attacks“. Zugegriffen: 24. November 2025. [Online]. Verfügbar unter: <https://www.kaggle.com/datasets/jigsaw-team/wikipedia-talk-labels-personal-attacks>
- [9] „Stanford Politeness Corpus (Wikipedia) — convokit 4.0.0 documentation“. Zugegriffen: 24. November 2025. [Online]. Verfügbar unter: https://convokit.cornell.edu/documentation/wiki_politeness.html
- [10] „Research:Detox/Data Release - Meta-Wiki“. Zugegriffen: 24. November 2025. [Online]. Verfügbar unter: https://meta.wikimedia.org/wiki/Research:Detox/Data_Release
- [11] S. Walsh und P. Greaney, „Multiclass hate speech detection with an aggregated dataset“, *Nat. Lang. Process.*, Bd. 31, Nr. 6, S. 1350–1366, Nov. 2025, doi: 10.1017/nlp.2024.62.
- [12] M.-E. Keller u. a., „HOCON34k: A Corpus of Hate Speech in Online Comments from German Newspapers“, in *Information Integration and Web Intelligence: 26th International Conference, iiWAS 2024, Bratislava, Slovak Republic, December 2–4, 2024, Proceedings, Part I*, Berlin, Heidelberg: Springer-Verlag, Tháng Mười Hai 2024, S. 212–226. doi: 10.1007/978-3-031-78090-5_18.